TP INTRO IA N°2

Les survivants du Titanic

A rendre à santucci_j@univ-corse.fr

1. Les données

Les données d'apprentissage et de test sont disponibles sur kaggle qui un site de compétition du Machine Learning (chercher dans Google Kaggle Titanic et télécharger les données). Vous devez télécharger le fichiers Train (891 lignes et 12 colonnes) et le fichier Test (418 lignes et 11 colonnes)

1.1 Importation des données

Question 1.1 : Importer les données et visualiser les premières observations.
Pour cela , vous pouvez utiliser la librairie pandas :

```
import pandas as pd

train = pd.read_csv('data/train.csv', sep = ',')
```

1.2. Visualisation

Question 1.2 : Visualiser les 10 premières lignes du fichier (à analyser) avec la commande train.-

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35	0	0	373450	8.0500	NaN	S
5	6	0	3	Moran, Mr. James	male	NaN	0	0	330877	8.4583	NaN	Q
6	7	0	1	McCarthy, Mr. Timothy J	male	54	0	0	17463	51.8625	E46	S
7	8	0	3	Palsson, Master. Gosta Leonard	male	2	3	1	349909	21.0750	NaN	S
8	9	1	3	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female	27	0	2	347742	11.1333	NaN	S
9	10	1	2	Nasser, Mrs. Nicholas (Adele Achem)	female	14	1	0	237736	30.0708	NaN	C

head(10). Vous allez obtenir le résultat suivant.

1.3. Indexation des données

Question 1.3 : Indexer les données (créer une colonne permettant d'indexer le fichier précédent).
Pour cela on va utiliser l'instruction de pandas :
DataFrame.set_index(keys, drop=True, inplace=True) où :

- keys est la colonne du fichier utilisée comme index,
- drop=True signifie que cette colonne choisie sera supprimée dans le nouveau fichier
- Inplace = True signifie que l'on va modifier le fichier passé en paramètre et pas créer un nouvel objet.

Nous allons indexer le fichier Train avec la colonne PassengerId donc : train.set_index('PassengerId', inplace=True, drop=True)

1.4. Analyse des variables

Nous voulons visualiser les variables du problème en affichant le noms des colonnes du fichier l'aide train.columns.

Question 1.4.1 : Ecrire la commande qui permet de visualiser les noms.

Vous devriez obtenir le résultat suivant :

```
Index([u'PassengerId', u'Survived', u'Pclass',
u'Name', u'Sex', u'Age', u'SibSp',
u'Parch', u'Ticket', u'Fare', u'Cabin',
u'Embarked'], dtype='object')
```

Question 1.4.2 : Faites une analyse des variables suivantes : Survived, PClass, Name, Sex, Age, SibSp,Parch, Ticket, Fare, Cabin, Embarked.

L'analyse consistera à faire le bilan des variables à l'aide des informations disponibles sur le web. Vous allez donc pour chaque colonne (à part PassengerId qui sert seulement pour indexer le fichier) analyser :

. ce que signifie la variable

. le type de la variable

. si certaines valeurs de la variable sont manquantes pour certains passagers.

Question 1.4.3 : Utiliser respectivement les commandes dtype et count qui vont vous donner respectivement le type des données et le nombre de valeurs non nulles par variables.

Vous allez obtenir le résultat suivant

Survived – int64 Pclass – int64 Name – object Sex – object Age – float64 SibSp – int64 Parch – int64 Ticket – object Fare – float64 Cabin – object Embarked – object dtype: object	Survived – 891 Pclass – 891 Name – 891 Sex – 891 Age – 714 SibSp – 891 Parch – 891 Ticket – 891 Fare – 891 Cabin – 204 Embarked – 889

Cette analyse permet d'avoir une vue d'ensemble du problème et fournit une aide pour définir les modèles d'apprentissage.

2. Premier Modèle

Généralement le premier modèle vise à établir un modèle rapide à concevoir qui sert de base de comparaison aux autres modèles plus complexes qu'il vous faudra concevoir par la suite.

Les trois variables SibSp, Parch et Fare sont faciles à utiliser car elles sont de type intfloat et aucune valeur n'est manquante (remarque : la variable PClass est de type intfloat mais n'est pas continue). Ces trois variables sont complètes et donc pas de reflexion sur d'éventuelles valeurs manquantes à compléter.

Pour le premier modèle vous pouvez utiliser ces variables.

2.1. Préparation des données

Avant de définir le modèle, vous allez préparer les données.

A partir du fichier train vous devez récupérer :

- d'une part le vecteur de sortie qu'on appellera par exemple target (vecteur à prédire) donc la variable Survived et
- d'autre part de filter le fichier pour ne considérer que les trois variables précédentes au sein d'une matrice X .

Question 2.1 : Pour cela vous écrirez une fonction parse_model_1 qui prendra en paramètre un fichier de type train et retournera le vecteur de sortie y (Colonne Survived du fichier passé en paramètre et la matrice X qui est un sous-ensemble du fichier passé en paramètre qui a été filtré avec les trois colonnes correspondants aux trois variables.

Vous devez donc obtenir une matrice X du type suivant :

	Fare	SibSp	Parch
PassengerId			
1	7.2500	1	0
2	71.2833	1	0
3	7.9250	0	0
4	53.1000	1	0
5	8.0500	0	0

2.2. Stratégie de Validation

On va choisir la validation croisée.

Question 2.2.1 : Donner selon vous les raisons de choisir une validation croisée.

Indication : Dans notre cas, le jeu de données est très petit et utiliserons simple validation basée sur un split unique risque de ne pas donner de bon résultats. Une validation croisée doit permettre l'obtention de meilleurs résultats.

Pour réussir une validation significative, on se propose d'utiliser la moyenne de plusieurs validations croisées (par exemple 5).

Question 2.2.2 : Ecrire une fonction compute_score qui prend comme paramètre un classifieur, la matrice X et la cible y et qui retourne la moyenne de 5 validations croisées (on entraine sur 4/5 du jeu de données et on teste sur le 1/5 restant. (Indication : utiliser le module cross_val_score qui va réaliser 5 validations croisées du classifier passé en paramètre)

Question 2.2.3 : Calculer le modèle de regression logistique (qui constituera votre 1er modèle de prédiction) et utiliser la fonction compute_score de la question 2.2.2 pour obtenir le score qui indique la qualité de la prédiction. Ce score sera le score à battre avec les autres modèles que vous allez écrire.

Remarque : vous pourriez être tenté d'essayer d'autres algorithmes plus complexes mais le gain sera pas très important. Il vaut mieux d'abord s'intéresser aux autres variables.

3. Etude des variables.

Il existe de nombreuses méthodes qui permettent de qualifier l'importance des variables d'entrée basées sur la réalisation de tests statistiques. Ces méthodes fonctionnent très bien mais l'interprétation des résultats repose sur l'expérience pour interpréter les résultats de ce type de méthodes.

Nous allons explorer une méthode simple pour qualifier l'importance des variables d'un problème donnée en Machine Learning.

3.1. Préparation de la méthode

Il voit falloir diviser la population en deux sous-populations en fonction de la variable à prédire et-tracer l'histogramme de la distributions des sous-populations pour cette variable

Question 3.1.1 : Vous allez tout d'abord séparer les données en deux populations, les survivants et les victimes. avec les instructions suivantes :

survived = train[train.Survived == 1]

dead = train[train.Survived == 0]

Il faut maintenant observer la distribution comparée des variables de ces deux populations, par exemple, sur la variable Pclass (ou d'autres).

Question 3.1.2 : Ecrire la fonction plot_hist qui prend en arguments le nom d'une des variables des données (Pclass ou autres) et qui trace l'histogramme de la distribution des survivants et des victimes pour la variable passée en paramètre.

3.2. Etude de la variable Pclass.

Nous allons tout d'abord étudier la variable Pclass

Question 3.2.1 : Afficher l'histogramme de la distribution des survivants et des victimes pour la variable Pclass en utilisant la fonction plot_hist. Vous devez obtenir un résultat du type ci-dessous:

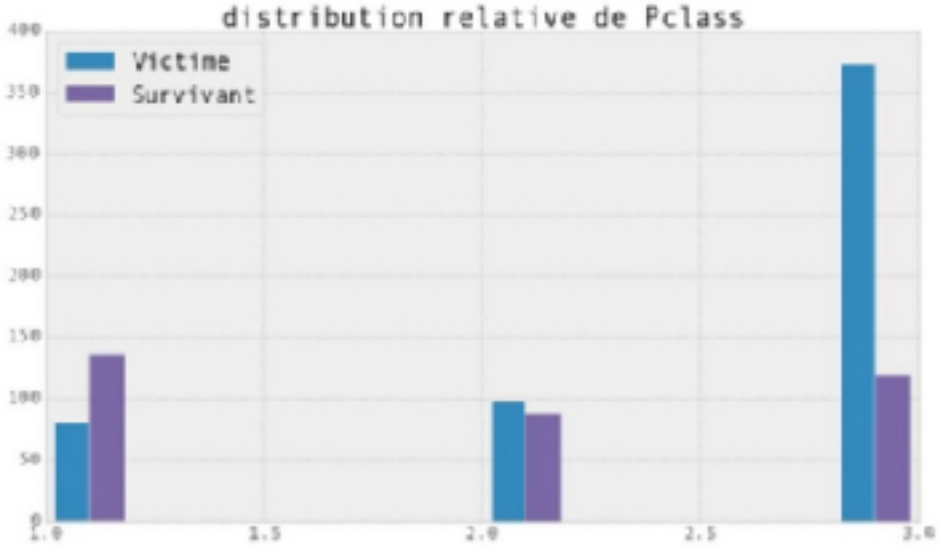

Question 3.2.2 : La variable Pclass est une variable importante. Pourquoi ?

Pour répondre à cette question, vous devez observer la distribution relative de la classe Pclass donc étudier si on peut discriminer les survivants et les victimes pour les trois classe : 1, 2 et 3.

3.3 Traitement de la variable Pclass

Puisque la variable Pclass est une variable importante, il faudra l'intégrer dans le prochain modèle.

Or cette variable est catégorielle (qu'on pourrait aussi considérer comme ordonnée aussi) : il faut effectuer certains traitements avant de l'intégrer dans un modèle. Nous allons la transformer en variables de type booléens. En effet comme la variable possède peu de modalités (les classes 1,2, 3) on peut créer des nouvelles variables (Pclass_1, Pclass_2 et P_class3).

La création. de ces variables (qu'on appelle dummies) se fera automatiquement en utilisant la librairie pandas : pd.get_dummies(X['Pclass'], prefix='split_Pclass')

Cela permet d'obtenir trois vecteurs booléen pour chacune des modalités de Pclass.

Question 3.3.1 : Ecrire la fonction parse_model_2 en injectant les instructions précédentes dans la fonction parse_model_1 de la question 2.1.

Question 3.3.2 : Afficher la nouvelle matrice X que l'on obtient

Indication : vous devez obtenir un résultat de ce type :

	SibSp	Parch	Fare	split Pclass 1	split Pclass 2	split Pclass 3
PassengerId						
1	1	0	7.2500	0	0	1
2	1	0	71.2833	1	0	0
3	0	0	7.9250	0	0	1
4	1	0	53.1000	1	0	0
5	0	0	8.0500	0	0	1

3.4 Validation du 2ème modèle.

Question 3.4.1 : Calculer le modèle de régression logistique avec ce deuxième modèle et calculer le score de validation croisée avec ce nouveau modèle.

Question 3.4.2 : Que remarquez vous? (indication : a-t-on améliorer le 1er modèle?).

Nous pouvons aussi nous intéresser au points des différents variables dans le modèle de régression utilisé.

Pour cela nous pouvons afficher les coefficients associés à chaque variable de la régression logistique.

Question 3.4.3 : Tracer les coefficients de la régression logistique en écrivant une fonction qui affiche les coefficients : plot_lr_coefs(X, lr) où X est la matrice des données d'entrainement et lr un classifieur de régression logistique. vous devez obtenir un graphique de ce type.

-

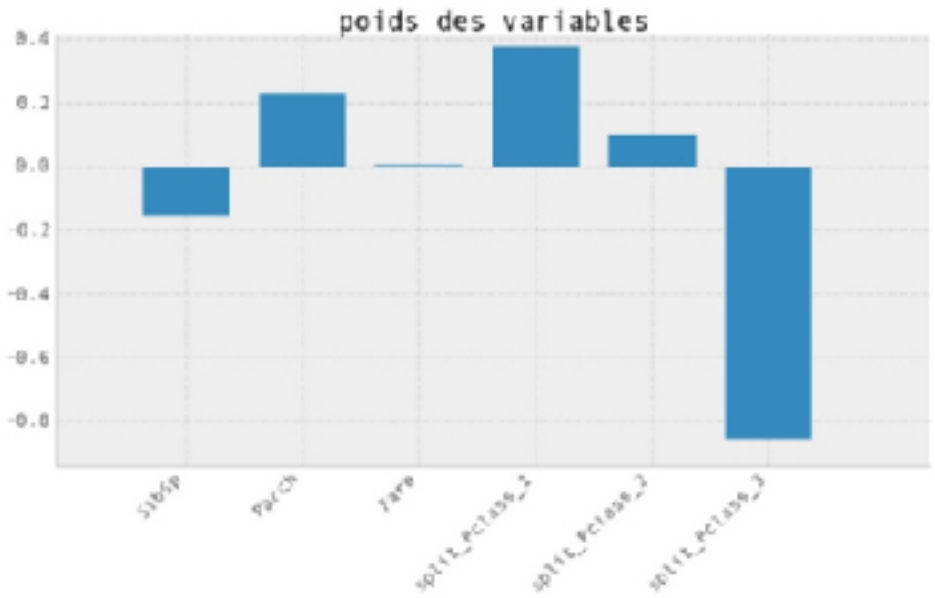

Interprétation de l'analyse des poids des variables :

- un poids positif ou un poids négatif important met en évidence l'importance de la variable dans le résultat du modèle.

- un poids proche de zéro signifie que l'influence de la variable est négligeable.

Question 3.4.4 : Donner une interprétation concernant les variables du modèle 2 à partir du graphique de la question 3.4.3

4. Etude plus fine des variables.

Des indications mettent en avant que les stratégies d'embarquement des canots de sauvetage ont été différentes à bâbord et à tribord. A tribord « les femmes et les enfants d'abord » a été appliqué en priorité mais pas en exclusivité donc des hommes pouvaient monter sur les canots. Coté bâbord les hommes avaient l'interdiction systématique de monter sur les canots (stratégie pas très maligne puisque il n'y avait que 500 femmes et enfants pour 1200 places dans les canots.

Donc il semble intéressant de s'intéresser aux variables Age et Sex. Il faut cependant traiter ces variables car d'une part Sex est de type string et Age n'est remplie qu'à 80%.

Pour la Class Age, la transformation sera effectuée comme pour la variable PClass : elle sera binarisée en créant deux variables dummy de type booléen.

Pour la variable Age, nous emploierons la stratégie qui va consister à remplir les valeurs manquantes avec une valeur correspond à la médiane de la distribution.

4.1. Création d'un nouveau jeu de données avec les variable Sex et Age

Question 4.1 : Ecrire la fonction parse_model_3 en injectant les instructions permettant s'insérer les variables Age et Sex dans la fonction parse_model_2 de la question 3.3.1.

Indication : Pour Sex on utilisera les mêmes instructions que pour la variable Pclass (variables dummy) et pour la variable Age, on complétera les valeurs manquantes en utilisant la méthode fillna de pandas.

4.2 Calcul du nouveau modèle et évaluation du nouveau score

Question 4.2.1 : Utiliser la régression logistique comme précédemment pour calculer le nouveau modèle et calculer le nouveau score.

Vous devez remarquer une nette amélioration du score. En utilisant la fonction plot_lr_coefs(X, lr) de la question 3.4.3 , nous pouvons analyser le poids du modèle 3.

Question 4.2.2 : Afficher le graphique permettant d'analyser le poids des variables du modèle 2.

Indication : vous devriez obtenir le graphique suivant :

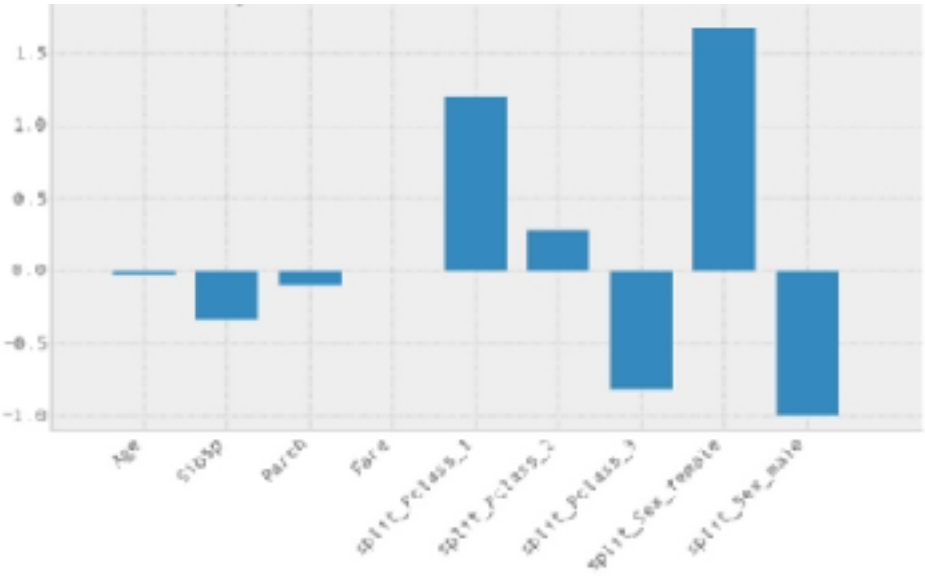

Question 4.2.3 : quelles conclusions faites vous pour ce qui concerne l'amélioration du modèle (est ce due à la variable Age ou aux variable de type Sex?

Nous allons donc étudier un peu plus en détail la variable Age.

4.3. Etude de la variable Age et nouveau modèle

Afin d'étudier l'importance de la variable Age, nous allons utiliser la fonction plot_hist de la question 3.1.2

Question 4.3.1 : Tracer les histogrammes des survivants et des victimes pour la variable Age. Vous devez obtenir une distribution du type ci-dessous :

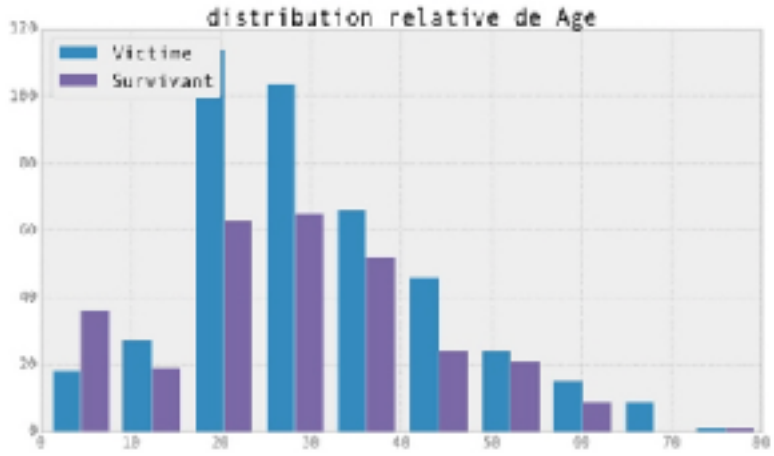

Question 4.3.2 : que remarquer vous pour les enfants et et les 20 et 30 ans?Apres l'analyse de la variable Age, nous voyons l'intérêt de créer des nouvelles variables comme par exemple une variable permettant de mettre en évidence le fait d'être un enfant. On va ajouter la variable is_child grâce à l'instruction : X['is_child'] = X.Age < 8

Question 4.3.3 : Ajouter cette instruction pour obtenir un nouveau modèle permettant de prendre en compte la variable is_child.

Question 4.3.4 : Comme précédemment (question 2.2.3) calculer le nouveau modèle et le score associé.

Question 4.3.5 : Vérifier que le score obtenu correspondant à une amélioration est du à l'introduction de la variable is_child (pour cela utiliser la fonction plot_lr_coefs(X, lr) de la question 3.4.3). Indication : vous devriez obtenir le graphique ci-dessous

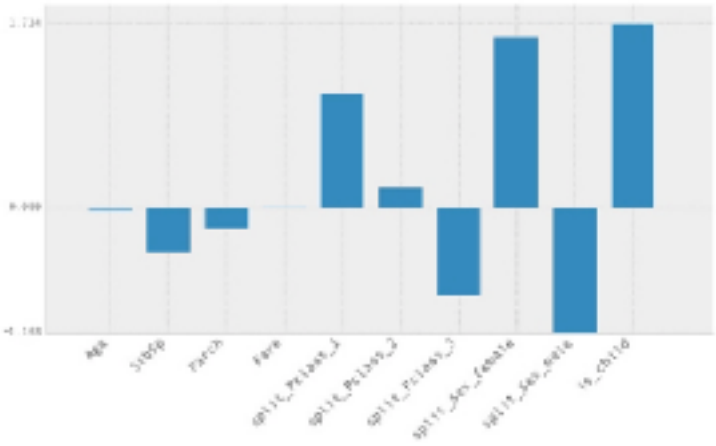

5. Modèles non linéaires

Nous avons réussi à prendre en compte l'effet de la non linéarité de variables (exemple le fait dire un enfant) par un modèle linéaire comme la régression logistique et intervenant sur les données (en créant la variable is_child).

Nous allons voir maintenant comment utiliser des modèles non linéaires qui sont faits en particulier pour prendre en compte ce genre d'information cachée. Mais dans tous les cas créer les bonnes variables sera la meilleure façon d'obtenir les meilleures performances des modèles que vous créerez.

5.1. Modèles de type Random Forest

Les modèles non linéaires sont simples à utiliser dans sciait learn (comme vu en cours).

Nous allons prendre comme exemple le module Random Forest sans créer dans un premier temps la variable is_child (juste pour observer les résultats obtenus).

Question 5.1.1 : Appliquer le classifieur RandomForest de scikit learn sur le modèle sans la variable child et calculer le nouveau score obtenu.

Question 5.1.2 : Que remarquez vous?

5.2. Interprétation du résultats avec RandomForest

Puisque le classifieur Random Forest est de type non linéaire, nous ne pouvons plus utiliser le poids des variables comme dans les questions précédentes pour analyser le modèle.
Vous allez pouvoir utiliser une nouvelle fonction permettant d'interpréter les résultats obtenus avec un classifieur de type Random Forest. Cette fonction clf_importance permet :

1. de tracer un schéma mettant en évidence l'importance relative des variables pour chaque arbre de la forêt. Chaque tracé correspond à un arbre (par défaut le nombre d'arbres est de 10). L'importance relative de chaque variable est indiquée en ordonnée et vous donne des indications sur la concentration plus ou moins forte de l'algorithme Random Forest.
2. de classer chaque variable en donnant sa contribution à l'algorithme.

Voila la fonction qui permet de tracer l'importance des variables :

```
def classifier_importance(X, clf):
        import pylab as pl
        importances = clf.feature_importances_
        indices = np.argsort(importances)[::-1]
        pl.title("Feature importances »)
        for tree in clf.estimators_:
                pl.plot(xrange(X.shape[1]), tree.feature_importances_[indices], « r")
        pl.plot(xrange(X.shape[1]), importances[indices], « b")
        pl.show()
        for f in range(X.shape[1]):
                print("%d. feature : %s (%f)" % (f+1, X.columns[indices[f]],
                        importances[indices[f]]))
```

Question 5.2.1 : Utiliser la fonction classifier_importance(X, clf) après avoir créer un classifieur de type Random Forest puis l'entrainer.
Vous devriez obtenir le schéma suivant qui met en évidence l'importance des variables dans l'algorithme :

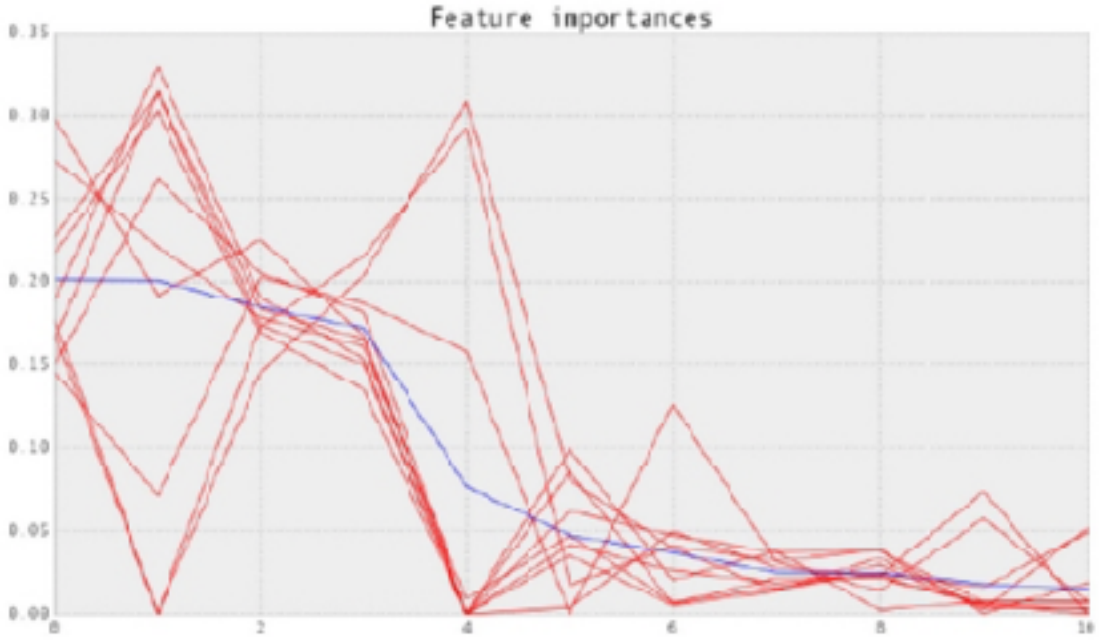

L'importance des variables représenter en abscisse est fourni en ordonnée. Les variables sont classées par ordre d'importance.

Le deuxième résultat de la fonction classifier_importance(X, clf) est de fournir la contribution de chaque variable :

```
1. feature : Fare (0.200859)
2. feature : split_Sex_female (0.200355)
3. feature : random (0.184521)
4. feature : Age (0.171788)
5. feature : split_Sex_male (0.076643)
6. feature : split_Pclass_3 (0.047177)
7. feature : split_Pclass_1 (0.036631)
8. feature : Parch (0.024891)
9. feature : SibSp (0.024589)
10. feature : split_Pclass_2 (0.017957)
11. feature : is_child (0.014590)
```

Question 5.2.2 : Que remarquez vous concernant l'importance des variables.

5.3 Utilisation des autres variables

Pour obtenir de bons résultats en Machine Learning, il faut prendre en compte les plus de variables caractéristiques possibles. Or on néglige souvent les variables que l'on a du mal à traiter comme les variables de type string car elles sont déstructurées ou qu'elles présentent des valeurs aberrantes ou manquantes.

Nous allons voir comment prendre en compte de telles variables.
Prenons comme exemple la variables name.

PassengerId	
1	Braund, Mr. Owen Harris
2	Cumings, Mrs. John Bradley (Florence Briggs Th...
3	Heikkinen, Miss. Laina
4	Futrelle, Mrs. Jacques Heath (Lily May Peel)
5	Allen, Mr. William Henry
6	Moran, Mr. James
7	McCarthy, Mr. Timothy J
8	Palsson, Master. Gosta Leonard
9	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)
10	Nasser, Mrs. Nicholas (Adele Achem)
11	Sandstrom, Miss. Marguerite Rut
12	Bonnell, Miss. Elizabeth
13	Saundercock, Mr. William Henry
14	Andersson, Mr. Anders Johan
15	Vestrom, Miss. Hulda Amanda Adolfina

Nous pouvons remarquer que la valeurs de la variable Name ont souvent la structure suivante : nom1, titre, nom2, nom3 (surnom) - surnom est optionnel.
On peut penser que l'information concernant le titre peut jouer un rôle important pour la classification.

Question 5.3.1 : Créer une nouvelle variable Title avec l'instruction suivante :
X['title'] = X.Name.map(lambda x : x.split(',')[1].split('.')[0])

Si vous examinez la variable Cabin, vous remarquerez que cette variable est très peu remplie mais cette variable est importante car elle comporte l'information de pont et donc de proximité avec les canots. Quand l'information n'est pas manquante, elle est de la forme : 'pont''numero de cabine'

Question 5.3.2 : Créer une nouvelle variable cabin avec l'instruction suivante :
X['cabin'] = X.Cabin.map(lambda x : x[0] if not pd.isnull(x) else -1)

Question 5.3.3 : Ecrire la fonction parse_model_5 (X) qui permet de créer un nouveau jeu de données en utilisant les nouvelles variables créées à partir de Name et Cabin et venant compléter le dernier jeu de données de la question 4.3.3
indication : attention vous devez utiliser des variables dummy pour les variables Title et cabin

Question 5.3.4 : Calculer le modèle de régression logistique correspond et calcul le score obtenu

Question 5.3.5 : Que remarquez vous?

6. Aller plus loin

6.1 Améliorer le modèle de régression logistique

Question 6.1.1 : Vous pouvez aussi étudier les autres variables : surname, embarked, ou ticket éventuellement.

Question 6.1.2 : Améliorer le remplissage des valeurs manquantes

6.2 Nouveaux modèles

Question 6.2.1 : Utiliser des modèles plus complexes (vous pouvez regarder la documentation concernant le boosting ou le SVM ou autre

Question 6.2.2 : Vous pouvez aussi choisir de meilleurs paramètres pour chacun des algorithmes.

-